

Нижегородский государственный университет им. Н. И. Лобачевского
Институт информационных технологий, математики и механики

Направление подготовки «Прикладная математика и информатика»

Магистерская программа Вычислительные методы и
суперкомпьютерные технологии

Образовательный курс «Методы глубокого обучения для решения задач
компьютерного зрения»

Отчёт

по лабораторной работе № 1

**«Реализация метода обратного распространения ошибки
для двуслойной полностью связанной нейронной сети»**

Выполнила:
студентка гр. 381703м3
Подчищаева М. В.

Нижний Новгород
2018

1. Постановка задачи

В ходе лабораторной работы предполагается решение *следующих задач*:

- Изучение общей схемы метода обратного распространения ошибки.
- Вывод математических формул для вычисления градиентов функции ошибки по параметрам нейронной сети и формул коррекции весов.
- Проектирование и разработка программной реализации сети, решающей задачу классификации рукописных символов.
- Тестирование разработанной программной реализации.
- Подготовка отчета, содержащего минимальный объем информации по каждому этапу выполнения работы.

Для обучения и тестирования сети предполагается использовать набор данных MNIST.

2. Вывод математических формул для вычисления градиентов функции ошибки по параметрам нейронной сети и формул коррекции весов и общая схема метода обратного распространения ошибки

Пусть нейронная сеть имеет: N - входных нейронов, K - нейронов на скрытом слое и M - выходных.

В целом метод обратного распространения ошибки сводится к задаче минимизации функции ошибки относительно синаптических весов. В качестве целевой функции будем использовать кросс энтропию.

$$E(w) = -\frac{1}{L} \sum_{k=1}^L \sum_{j=1}^M y_j^k \ln(u_j^k),$$

где $y^k = (y_j^k)$, $j = \overline{1, M}$, $k = \overline{1, L}$ – k -й пример из обучающей выборки, $u^k = (u_j^k)$, $j = \overline{1, M}$, $k = \overline{1, L}$ – выход нейронной сети на входе $x^k = (x_i^k)$, $i = \overline{1, N}$, $k = \overline{1, L}$. Также учтем, что $x_0 = 1$ – новый нейрон.

Для вывода формул и реализации будем использовать предположение, что режим обучения последовательный. Корректировка весов выполняется для каждого элемента обучающей выборки, а также $\sum_{j=1}^M y_j = 1$ для задач классификации.

Выведем сначала формулы для одного конкретного элемента выборки. Пусть: $x^* = (x_i^*)$, $i = \overline{1, N}$, $y^* = (y_j^*)$, $j = \overline{1, M}$, $u^* = (u_j^*)$, $j = \overline{1, M}$, тогда целевая функция для конкретного примера имеет вид:

$$E(w) = -\sum_{j=1}^M y_j \ln(u_j)$$

Обозначим синаптические веса от входного слоя к скрытому – $w_{is}^{(1)}$, от скрытого к выходному – $w_{sj}^{(2)}$. Также обозначим $h(g_j) = \frac{e^{g_j}}{\sum_{i=1}^M e^{g_i}}$ – функция активации на выходном слое (softmax), $\varphi(f_s) = \tanh(g_j)$ – функция активации на скрытом слое (гиперболический тангенс). В нашем случае все формулы для прямого прохода от входа к выходу выглядят следующим образом:

$$f_s = \sum_{i=0}^N w_{is}^{(1)} x_i, s = \overline{0, K}$$

$$v_s = \varphi(f_s), s = \overline{0, K}$$

$$g_j = \sum_{s=0}^K w_{sj}^{(2)} v_s, j = \overline{1, M}$$

$$u_j = h(g_j), j = \overline{1, M}$$

Итак, с учетом всех вышеуказанных формул и предположений:

$$E(w) = - \sum_{j=1}^M y_j \ln \left(\frac{e^{g_j}}{\sum_{i=1}^M e^{g_i}} \right) = - \sum_{j=1}^M y_j \left(g_j - \ln \left(\sum_{i=1}^M e^{g_i} \right) \right),$$

$$g_j = \sum_{s=0}^K w_{sj}^{(2)} \varphi \left(\sum_{i=0}^N w_{is}^{(1)} x_i \right)$$

Поскольку уже говорилось, что задача сводится к минимизации функции ошибки, в частности градиентными методами, то корректировка весов должна выполняться по следующим формулам:

$$w_{is}^{(1)(r+1)} = w_{is}^{(1)(r)} - \eta \frac{\partial E(w)}{\partial w_{is}^{(1)}}$$

$$w_{sj}^{(2)(r+1)} = w_{sj}^{(2)(r)} - \eta \frac{\partial E(w)}{\partial w_{sj}^{(2)}},$$

где η – скорость обучения ($0 < \eta < 1$).

Получим градиент для корректировки весов.

Частная производная целевой функции по весам от скрытого к выходному слою.

$$\frac{\partial E(w)}{\partial w_{sj}^{(2)}} = \frac{\partial E}{\partial g_j} \frac{\partial g_j}{\partial w_{sj}^{(2)}} = \delta_j^{(2)} v_s$$

$$\frac{\partial g_j}{\partial w_{sj}^{(2)}} = v_s$$

$$\delta_j^{(2)} = \frac{\partial E}{\partial g_j} = \left(\sum_{j=1}^M y_j \right) \frac{e^{g_j}}{\sum_{i=1}^M e^{g_i}} - y_j = \frac{e^{g_j}}{\sum_{i=1}^M e^{g_i}} - y_j = u_j - y_j$$

Частная производная целевой функции по весам от входного к скрытому слою.

$$\frac{\partial E(w)}{\partial w_{is}^{(1)}} = \frac{\partial E}{\partial f_s} \frac{\partial f_s}{\partial w_{is}^{(1)}} = \delta_s^{(1)} x_i$$

$$\delta_s^{(1)} = \frac{\partial E}{\partial f_s} = \sum_{j=1}^M \frac{\partial E}{\partial g_j} \frac{\partial g_j}{\partial v_s} \frac{\partial \varphi}{\partial f_s} = \frac{\partial \varphi}{\partial f_s} \sum_{j=1}^M \frac{\partial E}{\partial g_j} \frac{\partial g_j}{\partial v_s} = \frac{\partial \varphi}{\partial f_s} \sum_{j=1}^M \delta_j^{(2)} w_{sj}^{(2)}$$

$$\frac{\partial \varphi}{\partial f_s} = (1 - \varphi)(1 + \varphi) = (1 - v_s)(1 + v_s)$$

Алгоритм метода обратного распространения ошибки

1. Инициализация весов w некоторыми значениями

2. $for\ epoch = \overline{1, maxEpochs}$

3. $for\ i = \overline{0, W \cdot H}$

4. Прямой проход нейронной сети

5. Обратный проход

6. Шаги 3-5 повторяются до тех пока, пока не выполнится критерий остановки. Как правило, это либо максимальное число эпох, либо достигнутая точность обучения.

Прямой проход.

На вход подается x_i . Необходимо вычислить значения выходных сигналов нейронов скрытого слоя v_s , $s = \overline{0, K}$, где K - количество нейронов на скрытом слое и значение производной функции активации на скрытом слое $\frac{\partial \varphi}{\partial f_s}$.

Обратный проход:

Вычислим значения градиентов целевой функции, начиная с конца:

$$\delta_j^{(2)} = u_j - y_j, \frac{\partial E(w)}{\partial w_{sj}^{(2)}} = \delta_j^{(2)} \cdot v_s, j = \overline{1, M}$$

Скрытый слой, $s = \overline{0, K}$:

$$\delta_s^{(1)} = -\frac{\partial \varphi}{\partial f_s} \left[\sum_{j=1}^M \delta_j^{(2)} \cdot w_{sj}^{(2)} \right], \frac{\partial E(w)}{\partial w_{is}^{(1)}} = \delta_s^{(1)} \cdot x_i$$

По дугам:

$$w_{is}^{(1)} = w_{is}^{(1)} - \eta \frac{\partial E(w)}{\partial w_{is}^{(1)}},$$

$$w_{sj}^{(2)} = w_{sj}^{(2)} - \eta \frac{\partial E(w)}{\partial w_{sj}^{(2)}}.$$

3. Описание программной реализации

В ходе лабораторной работы была реализована программа для обучения двуслойной нейронной сети, решающей задачу классификации, на языке программирования Python 3.6. Класс *NNetwork* решает задачу обучения нейронной сети. Программа принимает следующие параметры:

1. Количество эпох
2. Требуемое значение кросс-энтропии
3. Скорость обучения
4. Количество нейронов на скрытом слое

Если параметры не переданы, то в качестве вышеупомянутых значений будут использованы значения по умолчанию. Данные параметры передаются в конструктор класса *NNetwork*.

Для обучения созданной сети на примерах из обучающей выборки используется метод *train()*, на вход которому подаются изображения из обучающей выборки и векторы, имеющие одну единичную компоненту, номер которой соответствует цифре, изображенной на картинке. Обучение сети заканчивается либо по количеству эпох, либо по достигнутому значению точности.

Затем вызывается метод *test()*, принимающий на вход аналогичные данные для тестовой выборки и предсказывает по ним выход с помощью ранее обученной сети.

Для запуска программы необходимо клонировать репозиторий, установить пакет *numpy* и запустить *python* интерпретатор на файле *Train.py*.

4. Результаты экспериментов

Обучение сети проходило на тренировочной выборке размера 60000 изображений, тестирование - на тестовой выборке набора данных MNIST размера 10000 изображений. Требуемое значение кросс-энтропии для всех экспериментов было указано 0.001, количество эпох - 10. Результаты представлены в таблице ниже.

Количество нейронов на скрытом слое	Скорость обучения	Точность на обучающей выборке	Точность на тестовой выборке
500	0,01	0,95	0,93
500	0,001	0,92	0,91
800	0,01	0,95	0,95
800	0,001	0,93	0,91
1000	0,01	0,96	0,94